

UNIVERSIDAD TÉCNICA PARTICULAR DE LOJA

Carrera de Ciencias de la Computación

ASIGNATURA: PRACTICUM 1.2

TEMA DEL INFORME:

Estado del Arte sobre Analítica, Ingeniería y Visualización de Datos

Presentado por:

Rodrigo Seraquive

Fecha: 12/06/2026

Ubicación: Loja – Ecuador



Tabla de Contenido

1. INTRODUCCIÓN Y CONTEXTO ACADÉMICO	3
2. MARCO CONCEPTUAL AVANZADO Y ARQUITECTURA	3
2.1 Arquitectura Medallón (Bronze-Silver-Gold)	3
2.2 El Paradigma de Integración: Evolución de ETL a ELT	4
2.3 Repositorios y Modelos: Data Warehouses vs. Data Lakes	4
2.4 El Paradigma Híbrido: Data Lakehouse	4
3. INGENIERÍA Y MODELADO RELACIONAL DE LA CAPA SILVER	5
3.1 Modelado Dimensional de Kimball y Esquema Estrella	5
3.2 Orquestación y Gobierno de Pipelines Modernos	5
4. ANALÍTICA DE DATOS Y MARCOS METODOLÓGICOS	6
4.1 Taxonomía y Fases Evolutivas de la Analítica	6
4.2 Frameworks Metodológicos de Ciencia de Datos	6
5. VISUALIZACIÓN E INTELIGENCIA DE NEGOCIOS (BI)	7
5.1 Principios Cognitivos e Importancia de la Visualización	7
5.2 Formatos Gráficos y su Aplicación Analítica	7
6. MATRIZ DE COMPARACIÓN DE HERRAMIENTAS Y TECNOLOGÍAS	8
7. TENDENCIAS TECNOLÓGICAS Y HORIZONTE FUTURO (2025-2030)	8
8. CONCLUSIONES	9
9. REFERENCIAS BIBLIOGRÁFICAS	10

1. INTRODUCCIÓN Y CONTEXTO ACADÉMICO

En el entorno tecnológico e industrial contemporáneo, los datos se han consolidado como el recurso estratégico e intangible de mayor valor para las organizaciones y los sistemas informáticos modernos. La proliferación de sensores, dispositivos móviles y servicios basados en computación en la nube han provocado una generación masiva de datos en tiempo real. Esta situación exige marcos metodológicos y patrones de arquitectura rigurosos para la ingesta, el almacenamiento óptimo y el procesamiento de la información, con el propósito explícito de mitigar riesgos corporativos y guiar de forma empírica la toma de decisiones estratégicas (Kelleher & Tierney, 2020).

La formación de profesionales en Ciencias de la Computación demanda el dominio de infraestructuras capaces de responder eficazmente a las demandas reales del mercado laboral. Bajo este contexto, el presente Estado del Arte estructura una revisión crítica, sistemática y rigurosa sobre el ecosistema unificado que integra la Ingeniería de Datos, la Analítica de Datos y la Visualización de Datos. El propósito es fundamentar teóricamente el diseño de pipelines automatizados robustos, basándose estrictamente en literatura científica de frontera publicada entre los años 2020 y 2023 en repositorios indexados (Armbrust et al., 2021).

2. MARCO CONCEPTUAL AVANZADO Y ARQUITECTURA

2.1 Arquitectura Medallón (Bronze-Silver-Gold)

La arquitectura medallón constituye un patrón de diseño lógico para la organización estructurada de datos dentro de un entorno analítico moderno, estableciendo tres capas de calidad de datos y refinamiento progresivo. Este enfoque garantiza la trazabilidad y la aplicación de principios transaccionales sobre repositorios distribuidos de objetos (Jain et al., 2023):

- **Capa Bronze (Raw Data):** Actúa como la zona de ingesta inicial y fuente de verdad inmutable. Preserva los archivos y registros heterogéneos provenientes de los sistemas origen en su formato nativo y crudo, sin ninguna transformación (Sawadogo & Darmont, 2021).
- **Capa Silver (Cleansed/Enriched Data):** Representa la fase de consolidación y calidad. En esta capa se aplican procesos de limpieza, tipado de datos estricto, normalización y eliminación de registros duplicados (Machado et al., 2022).

- **Capa Gold (Curated Business Data):** Es la capa final orientada al negocio. Estructura y materializa agregaciones, resúmenes analíticos y tablas derivadas diseñadas para responder preguntas de negocio específicas e indicadores clave de rendimiento (Kimball & Ross, 2013).

2.2 El Paradigma de Integración: Evolución de ETL a ELT

Tradicionalmente, el proceso de integración se ha regido por el enfoque ETL (Extract, Transform, Load), diseñado para bases de datos relacionales con recursos de cómputo limitados, donde las transformaciones pesadas debían ejecutarse en un área intermedia de staging antes de la carga (Kimball & Ross, 2013). No obstante, la consolidación de la computación elástica en la nube y el almacenamiento masivo han impulsado la adopción mayoritaria del paradigma ELT (Extract, Load, Transform). Bajo este nuevo enfoque, los datos masivos se extraen y cargan directamente en su formato crudo dentro del repositorio destino y posteriormente se transforman utilizando la potencia de cómputo distribuido nativa (Machado et al., 2022).

2.3 Repositorios y Modelos: Data Warehouses vs. Data Lakes

El almacenamiento analítico ha evolucionado a través de dos vertientes históricas. El Data Warehouse representa un sistema centralizado diseñado para almacenar y gestionar de forma óptima grandes volúmenes de datos puramente estructurados mediante motores relacionales (Kimball & Ross, 2013). Por el contrario, un Data Lake es un repositorio flexible diseñado para almacenar datos estructurados, semiestructurados y no estructurados en su formato original de manera económica. Sin embargo, tal como advierten Sawadogo y Darmont (2021), la ausencia de zonas de calidad progresiva puede transformar un Data Lake en un depósito de datos inútiles e inaccesibles ('data swamp').

2.4 El Paradigma Híbrido: Data Lakehouse

Para resolver las limitaciones de ambos esquemas, surge el Data Lakehouse como una arquitectura híbrida unificada. Este paradigma combina la flexibilidad, escalabilidad y bajo costo de almacenamiento de un Data Lake con las garantías transaccionales ACID (Atomicidad, Consistencia, Aislamiento y Durabilidad) de un Data Warehouse tradicional (Armbrust et al., 2021). Técnicamente, esta arquitectura se habilita mediante formatos de tabla abiertos que corren

sobre almacenamiento de objetos, permitiendo que múltiples motores avanzados interactúen simultáneamente sobre el mismo repositorio sin duplicar la información (Jain et al., 2023).

3. INGENIERÍA Y MODELADO RELACIONAL DE LA CAPA SILVER

3.1 Modelado Dimensional de Kimball y Esquema Estrella

El diseño lógico de la Capa Silver y su transición hacia la Capa Gold requiere metodologías de modelado formal. El modelado dimensional propuesto por Kimball y Ross (2013) es el estándar vigente para estructurar almacenes analíticos a través del patrón de Esquema Estrella. Este diseño se compone de:

- Tablas de Hechos (Fact Tables): Posicionadas en el centro del esquema, contienen las métricas numéricas, contadores y eventos cuantitativos de los procesos de negocio.
- Tablas de Dimensiones (Dimension Tables): Rodean a la tabla de hechos y contienen los atributos descriptivos, jerarquías y textos que otorgan contexto y permiten filtrar las métricas.

A pesar de la evolución tecnológica, la modelación relacional sigue siendo ratificada como la herramienta indispensable para garantizar la integridad referencial, el linaje y evitar errores de diseño estructural antes del desarrollo de cualquier tubería automatizada de datos (Kimball & Ross, 2013).

3.2 Orquestación y Gobierno de Pipelines Modernos

Un pipeline de datos moderno es una secuencia de tareas interdependientes que debe ejecutarse bajo condiciones de automatización estrictas. La herramienta encargada de coordinar la programación, ejecución cronológica, manejo de fallos y monitoreo de estas tareas es el orquestador (Machado et al., 2022). El estándar de la industria está gobernado por plataformas de código abierto que utilizan Gráficos Acíclicos Dirigidos (DAGs) escritos en código para definir los flujos de trabajo de datos de manera flexible y de fácil mantenimiento.

4. ANALÍTICA DE DATOS Y MARCOS METODOLÓGICOS

4.1 Taxonomía y Fases Evolutivas de la Analítica

La Analítica de Datos se define formalmente como la aplicación sistemática de algoritmos computacionales, lógica matemática y modelado estadístico para descubrir patrones de comportamiento (Han et al., 2022). Metodológicamente, se organiza en cuatro fases de complejidad incremental descritas de manera estructurada en la Tabla 1.

Tipo de Analítica	Enfoque Metodológico y Descripción Académica
Analítica Descriptiva	Examina registros históricos detallados para identificar '¿qué ocurrió?' en una ventana de tiempo específica, utilizando agregaciones y resúmenes estadísticos básicos.
Analítica Diagnóstica	Evaluación de dependencias, variables y correlaciones estadísticas para responder '¿por qué ocurrió?' un fenómeno, aislando factores causales directos.
Analítica Predictiva	Integra modelos probabilísticos, series temporales y machine learning para inferir escenarios futuros respondiendo a la pregunta '¿qué es probable que ocurra?'.
Analítica Prescriptiva	Emplea motores de simulación, reglas de negocio avanzadas y optimización matemática para recomendar acciones concretas ante la pregunta '¿cómo podemos hacerlo ocurrir?'..

4.2 Frameworks Metodológicos de Ciencia de Datos

Para evitar el desarrollo ad-hoc de proyectos analíticos, la ciencia de datos contemporánea adopta marcos metodológicos estandarizados, interactivos e iterativos (Han et al., 2022). Estos frameworks guían al profesional desde el entendimiento del negocio y la comprensión de los datos, pasando por la preparación rigurosa, el modelado algorítmico, hasta la evaluación y el despliegue. Las investigaciones demuestran que la fase de preparación y limpieza de datos constituye de manera consistente la mayor inversión de tiempo del esfuerzo total de un proyecto (Han et al., 2022).

5. VISUALIZACIÓN E INTELIGENCIA DE NEGOCIOS (BI)

5.1 Principios Cognitivos e Importancia de la Visualización

La Visualización de Datos es la disciplina que traduce métricas cuantitativas e inferencias matemáticas complejas en representaciones gráficas abstractas, coherentes y dinámicas, con el objetivo explícito de acelerar la interpretación cognitiva del cerebro humano al mapear números en atributos visuales (Cairo, 2020). Su importancia dentro de la Inteligencia de Negocios radica en su capacidad para democratizar el acceso a la información y actuar como puente de comunicación (Few, 2020).

5.2 Formatos Gráficos y su Aplicación Analítica

La elección del formato gráfico óptimo no depende de criterios estéticos, sino de la naturaleza de las variables y del objetivo analítico del indicador, tal como se detalla de forma resumida en la Tabla 2.

Formato de Gráfico	Aplicación Analítica y Variables Relacionadas
Diagramas de Dispersión	Permiten mapear la correlación, dispersión y comportamiento simultáneo entre dos variables continuas distribuidas (Cairo, 2020).
Histogramas	Muestran la distribución de frecuencias y la densidad probabilística de una única variable numérica continua (Few, 2020).
Mapas de Calor (Heatmaps)	Utilizan escalas cromáticas proporcionales para indicar la intensidad, concentración o interrelación entre múltiples dimensiones (Cairo, 2020).

6. MATRIZ DE COMPARACIÓN DE HERRAMIENTAS Y TECNOLOGÍAS

El desarrollo de flujos unificados de datos combina múltiples tecnologías especializadas en cada pilar operativo. A continuación, se presenta un cuadro técnico comparativo basado en las herramientas evaluadas en la literatura analizada.

Tecnología	Área y Categoría	Uso Principal en la Infraestructura Unificada
Power BI / Tableau	Visualización / BI Comercial	Diseño de cuadros de mando unificados con KPIs interactivos y filtros contextuales (Few, 2020).
Python (pandas)	Analítica / Procesamiento	Scripts para la limpieza, imputación de valores nulos y transformación de datos tabulares (McKinney, 2022).
PostgreSQL	Ingeniería / Base de Datos	Motor relacional para soportar físicamente el modelado analítico de los esquemas (Kimball & Ross, 2013).
Apache Spark	Ingeniería / Procesamiento Distr.	Framework para el procesamiento a gran escala en memoria, actuando como motor analítico central (Armbrust et al., 2021).
Apache Airflow	Ingeniería / Orquestación	Automatización programática y monitoreo de pipelines de datos mediante la secuenciación de tareas (Machado et al., 2022).

7. TENDENCIAS TECNOLÓGICAS Y HORIZONTE FUTURO (2025-2030)

Las tendencias dominantes en la Línea Unificada de Datos apuntan de forma irreversible hacia la automatización y la descentralización. En primer lugar, la Inteligencia Artificial se integra a lo largo de toda la cadena: desde herramientas que automatizan la limpieza e imputación, hasta sistemas de visualización conversacionales que permiten extraer hallazgos mediante lenguaje natural (Cairo, 2020). No obstante, la literatura resalta que el criterio humano sobre diseño dimensional y gobernanza arquitectónica sigue siendo irremplazable (Kimball & Ross, 2013).

En segundo lugar, el paradigma Data Mesh impulsa que los diferentes dominios traten sus fuentes de información como productos de datos independientes con contratos de calidad explícitos, mejorando sustancialmente el linaje informático de las organizaciones (Machado et al., 2022). Finalmente, la consolidación de formatos de tabla abiertos garantiza un futuro donde múltiples motores relacionales avanzados operan de manera eficiente sobre el mismo repositorio centralizado de datos (Jain et al., 2023).

8. CONCLUSIONES

Primera: La Ingeniería de Datos, la Analítica y la Visualización de Datos no operan de forma aislada, sino como una infraestructura unificada y codependiente, donde la calidad del diseño arquitectónico en las capas iniciales determina directamente la validez de las decisiones corporativas finales.

Segunda: La adopción del patrón de Arquitectura Medallón (Bronze, Silver, Gold) combinado con el modelado dimensional de Kimball proporciona un marco robusto y estándar que evita la degradación de los repositorios analíticos, permitiendo un gobierno efectivo de la información.

Tercera: El avance de tecnologías como los formatos de tabla abiertos potencia la productividad técnica, pero incrementa la necesidad de que los futuros profesionales de Ciencias de la Computación posean un sólido criterio metodológico para estructurar datos integrados y fiables.

Referencias

- Armbrust, M., Ghodsi, A., Xin, R., & Zaharia, M. (2021). *Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics*. 11th Conference on Innovative Data Systems Research (CIDR 2021), 1–15.
- Cairo, A. (2020). *How Charts Lie: Getting Smarter about Visual Information*. W. W. Norton & Company.
- Few, S. (2020). *Now You See It: Simple Visualization Techniques for Quantitative Analysis* (2nd ed.). Analytics Press.
- Han, J., Kamber, M., & Pei, J. (2022). *Data Mining: Concepts and Techniques* (4th ed.). Morgan Kaufmann.
- Jain, P., Kraft, P., Power, C., Das, T., Stoica, I., & Zaharia, M. (2023). *Analyzing and comparing lakehouse storage systems*. 13th Conference on Innovative Data Systems Research (CIDR 2023).
- Kelleher, J. D., & Tierney, B. (2020). *Data Science* (2nd ed.). MIT Press.
- Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd ed.). John Wiley & Sons.
- Machado, I. A., Costa, C., & Santos, M. Y. (2022). *Data mesh: Concepts and principles of a paradigm shift in data architectures*. *Procedia Computer Science*, 196, 263-271. <https://doi.org/10.1016/j.procs.2021.12.033>
- McKinney, W. (2022). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter* (3rd ed.). O'Reilly Media.
- Sawadogo, P. N., & Darmont, J. (2021). *On data lake architectures and metadata management*. *Journal of Intelligent Information Systems*, 56(1), 97-120. <https://doi.org/10.1007/s10844-020-00608-7>