



UNIVERSIDAD TÉCNICA PARTICULAR DE LOJA
La Universidad Católica de Loja

INFORME DE PROYECTO: RETO 1

Del CSV al Dashboard: Pipeline de Datos Educativos con Python, SQLite y Power BI

Cuarto Ciclo

Estudiante: Rodrigo Seraquive

Materia: Computación

Fecha: Mayo 2026



El presente proyecto desarrolla un pipeline de datos educativos utilizando Python, SQLite y Power BI. El objetivo principal fue transformar datos educativos reales provenientes del Archivo Maestro de Instituciones Educativas (AMIE) del Ministerio de Educación del Ecuador en información organizada, limpia y visualmente interpretable.

Durante el desarrollo del reto se trabajó con el dataset histórico AMIE 2009–2024, aplicando procesos de exploración, limpieza, validación, almacenamiento en base de datos y visualización de información mediante dashboards. El proyecto permitió comprender cómo un conjunto de datos reales presenta problemas de calidad que deben ser tratados antes de realizar análisis o visualizaciones conceptuales avanzadas.

2. Objetivos

Objetivo General

Construir un pipeline de datos educativos utilizando Python, SQLite y Power BI para explorar, limpiar, almacenar y visualizar información educativa del Ecuador.

Objetivos Específicos

- Explorar el dataset AMIE identificando dimensiones, tipos de datos y valores nulos.
- Implementar procesos de limpieza y validación de datos estructurales.
- Cargar la información limpia y procesada en un motor de base de datos relacional local (SQLite).
- Ejecutar consultas SQL optimizadas para responder preguntas específicas de negocio.
- Construir un dashboard interactivo, dinámico e intuitivo en Power BI.

3. Herramientas Utilizadas

Herramienta	Uso y Aplicación en el Proyecto
Python 3.13	Procesamiento general, scripting y automatización de la limpieza de datos.
Pandas	Manipulación de estructuras de datos bidimensionales (DataFrames) y transformaciones del dataset.
SQLAlchemy	Capa de abstracción y conexión eficiente entre los scripts de Python y el motor SQLite.
SQLite	Base de datos local relacional para almacenamiento y estructuración de los datos consolidados.

Power BI	Construcción del dashboard interactivo y capa analítica visual.
Visual Studio Code	Entorno de desarrollo integrado (IDE) para la codificación y depuración de scripts.

4. Dataset Utilizado

Se trabajó con el dataset histórico AMIE 2009–2024 provisto por el Ministerio de Educación del Ecuador. Este registro condensa información estratégica sobre las instituciones educativas del país, segmentada por:

- Ubicación geográfica: Provincia, Cantón y Parroquia.
- Atributos institucionales: Sostenimiento (Fiscal, Particular, etc.), Modalidad y Área (Urbana/Rural).
- Métricas demográficas: Total de estudiantes, Total de docentes y Nivel educativo.

Desafíos de calidad de datos: Al tratarse de un registro administrativo real a gran escala, el archivo original presentó problemas críticos de calidad de datos que comprometían su análisis directo:

- Presencia significativa de valores nulos en campos numéricos.
- Inconsistencias en la codificación de caracteres especiales (acentos, eñes).
- Columnas con nomenclaturas heterogéneas o inconsistentes.
- Existencia de registros duplicados bajo la misma clave primaria institucional.

5. Desarrollo del Pipeline

5.1 Exploración del Dataset


En la primera etapa se realizó una auditoría inicial utilizando la librería pandas. El objetivo fue dimensionar el volumen de información y diagnosticar anomalías estructurales.

- Volumen total: El dataset original arrojó un total de 290,310 registros y 104 columnas.
- Diagnóstico: Se ratificó la existencia de duplicados y campos numéricos vacíos que requerían normalización.

5.2 Limpieza y Transformación de Datos

Se diseñó y ejecutó un script robusto en Python denominado 'limpieza.py' que aplicó las siguientes reglas de negocio:

- Estandarización de columnas: Eliminación de espacios y caracteres especiales. Ej. 'Ao lectivo' pasó a 'anio_lectivo', 'Total Estudiantes' a 'total_estudiantes'.
- Imputación de valores nulos: Reemplazo sistemático por cero (0) en columnas cuantitativas clave como 'total_docentes', 'total_estudiantes', 'estudiantes_f' y 'estudiantes_m'.
- Depuración de duplicados: Se eliminaron 2 registros duplicados usando el código identificador institucional único, garantizando la integridad referencial.
- Validación de consistencia: Se programó una aserción lógica para comprobar que la suma de 'estudiantes_m' y 'estudiantes_f' equivaliera exactamente a 'total_estudiantes'. El script arrojó 0 registros inconsistentes.



Nota: La ejecución exitosa fue verificada en consola asegurando un dataset de salida pulido.

5.3 Carga de Datos en SQLite

Una vez limpio el dataset, se procedió con la fase de carga (Load) hacia una base de datos relacional local mediante el script 'carga_sqlite.py' apoyado en SQLAlchemy.

- Base de datos generada: amie_mineduc.db
- Tabla destino: instituciones
- Volumen final cargado: 290,308 registros procesados de forma óptima.


```

1 import pandas as pd
2 from sqlalchemy import create_engine
3
4 print("Cargando dataset 'limpio...")
5
6 # Leer dataset 'limpio
7 df = pd.read_csv(
8     "data/dataset_limpio.csv",
9     low_memory=False
10 )
11
12 print("Dataset cargado correctamente")
13
14 # Crear base de datos
15 engine = create_engine('sqlite:///base_datos/analisis_educativo.db')
16
17 print("Base de datos creada correctamente")
18
19 # Guardar dataset en la base de datos
20 df.to_sql('dataset_limpio', engine, if_exists='replace', index=False)
21
22 print("Dataset guardado correctamente")
23
24 # Verificar la consistencia de los datos
25 query = "SELECT COUNT(*) FROM dataset_limpio"
26 result = pd.read_sql_query(query, engine)
27 print(f"Total registros: {result[0][0]}")
28
29 # Presión Finalizada correctamente
30 print("Presión Finalizada correctamente")

```

Dataset 'limpio' guardado correctamente
Total registros: 20000
Presión Finalizada correctamente

Nota: Se verificó la consistencia mediante herramientas de inspección SQL.

5.4 Consultas Analíticas (SQL)

Se estructuró el script 'consultas.py' para interrogar la base de datos y extraer respuestas clave para el negocio educativo:

- Pregunta 1 (Distribución por Provincia): Las provincias con el mayor volumen de matrícula nacional acumulada resultaron ser Guayas, Pichincha y Manabí.
- Pregunta 2 (Proporción en Loja): Al enfocar el análisis en la provincia de Loja, se observó un claro predominio de instituciones de sostenimiento fiscal tanto en el área urbana como rural.
- Pregunta 3 (Evolución histórica): Las consultas de agregación temporal revelaron una reducción progresiva en el número de instituciones educativas activas a nivel nacional entre los años 2009 y 2024.

```

-- P1 --
SELECT provincia, total_matricula
FROM dataset_limpio
GROUP BY provincia
ORDER BY total_matricula DESC
LIMIT 5;

-- P2 --
SELECT provincia, sector, sostenimiento, total_instituciones
FROM dataset_limpio
WHERE provincia = 'Loja'
GROUP BY provincia, sector, sostenimiento
ORDER BY provincia, sector, sostenimiento;

-- P3 --
SELECT año, total_instituciones
FROM dataset_limpio
GROUP BY año
ORDER BY año;

```

P1

provincia	total_matricula
GUAYAS	1200000
PICHINCHA	1000000
MANABÍ	800000
LOJA	500000
EL ZARZO	400000

P2

provincia	sector	sostenimiento	total_instituciones
Loja	Rural	Fiscal	200
Loja	Rural	Particular	100
Loja	Urbana	Fiscal	150
Loja	Urbana	Particular	100

P3


año	total_instituciones
2009-2010	2000
2010-2011	2000
2011-2012	2000
2012-2013	2000
2013-2014	2000
2014-2015	2000
2015-2016	2000
2016-2017	2000
2017-2018	2000
2018-2019	2000
2019-2020	2000
2020-2021	2000
2021-2022	2000
2022-2023	2000

Nota: Los outputs se desplegaron de manera estructurada en consola.

5.5 Dashboard Interactiva en Power BI

Como fase de visualización final, se conectó el archivo amie_mineduc.db a Power BI para moldear un cuadro de mando ejecutivo:

- KPI Principal: Tarjeta destacada con la Matrícula Nacional Total.
- Visualización 1: Gráfico de barras horizontales detallando la matrícula total por provincia.
- Visualización 2: Gráfico de barras apiladas al 100% que contrasta las instituciones por sostenimiento específicamente en la provincia de Loja.
- Visualización 3: Gráfico de línea temporal que dibuja con claridad la evolución histórica de los centros educativos activos.



Nota: La interfaz final ofrece filtros interactivos por año y región.

6. Conclusiones y Recomendaciones

Conclusiones

- El análisis de datos estratégico requiere estrictamente procesos previos de ETL (Extracción, Limpieza y Carga) para asegurar que los hallazgos visuales correspondan a realidades institucionales y no a ruidos lógicos.
- El ecosistema de Python (pandas + SQLAlchemy) demostró ser altamente eficiente para el procesamiento de datasets voluminosos que superan las capacidades analíticas de las hojas de cálculo tradicionales.
- SQLite constituye un motor ideal para fases de prototipado rápido, proporcionando una estructura relacional formal con un consumo mínimo de recursos.
- Power BI facilita la democratización de la información, transformando filas complejas de bases de datos en gráficos dinámicos comprensibles para la toma de decisiones directivas.

Recomendaciones

- Implementar validaciones automáticas adicionales (pipelines CI/CD de datos) para detectar de forma temprana cambios bruscos en los esquemas de los ministerios.
- Incorporar paneles analíticos con análisis predictivo básico (como proyecciones de deserción o demanda de docentes).
- Automatizar el flujo completo (por ejemplo, con herramientas de orquestación como Apache Airflow o scripts unificados) para actualizaciones periódicas automáticas.
- Migrar el almacenamiento hacia motores de bases de datos empresariales (PostgreSQL o soluciones Cloud) si el proyecto escala a niveles de concurrencia multinivel.

7. Anexos y Referencias

Archivos Generados en el Proyecto

- exploracion.py - Script de inspección inicial de dimensiones y nulos.
- limpieza.py - Script de normalización, filtrado e imputación de valores.
- carga_sqlite.py - Script de migración de datos hacia la base relacional.
- consultas.py - Script con queries SQL para las preguntas del negocio.
- dataset_limpio.csv - Archivo plano de datos normalizados.
- amie_mineduc.db - Base de datos SQLite completamente estructurada.
- dashboard_mineduc.pbix - Archivo fuente del dashboard interactivo en Power BI.

Referencias Bibliográficas

- Ministerio de Educación del Ecuador. (2024). Registros Administrativos del Archivo Maestro de Instituciones Educativas (AMIE).
- Pandas Development Team. (2026). Pandas Documentation for Data Manipulation. Recuperado de <https://pandas.pydata.org>
- SQLAlchemy Authors. (2026). SQLAlchemy Documentation and Object Relational Tutorial.